

迁移学习：回顾与进展

杨强¹ 童咏昕²

¹ 香港科技大学

² 北京航空航天大学

关键词：迁移学习 人工智能 小数据学习

创造智能的梦想，一直以来是激励人类在人工智能领域不断披荆斩棘的动力。人工智能也在一直不断地开拓新的技术和应用。然而，不断发展的人工智能技术对计算资源和数据资源的需求也在激增，逐渐成为人工智能新的瓶颈。

如何解决这一困境？近年来迁移学习逐渐走入人们的视野。迁移学习旨在将其“举一反三”的能力具象为算法框架，将某个领域的知识迁移到另一个领域的学习中，从而打破数据资源的桎梏。从20世纪90年代以来，迁移学习已经逐渐发展出了样本迁移、特征迁移、模型迁移和关系迁移等多个门类，并且和深度学习有了进一步的结合。在图片数据、文本数据等多种数据的学习建模领域崭露头角，建立起较为成熟的理论和实践体系，逐步将小数据学习从理论变为现实。

从人工智能到迁移学习

在20世纪60年代人工智能发展早期，人们认为智能来自逻辑，希望通过对计算物理符号的排列组合来实现人工智能，因此研究了诸如下棋、推理、路径规划等问题，并取得了一些成就。经过十几年发展，人们发现智能也可以来自程序的自我学习，并发明了各种各样的机器学习方法，包括神经网络。

从20世纪90年代一直到21世纪，随着机器计算能力的大幅提高，上述方法的可行性均得到部

分验证。1997年，“深蓝”通过在状态空间搜索打败了国际象棋世界冠军卡斯帕罗夫，其本质上是物理符号空间的排列组合计算。随着大数据时代的到来，更加有效的机器学习方法如卷积神经网络和深度神经网络等，使得从数据中获取智慧这一方案在语音处理、图像识别等诸多领域取得了巨大的成功。强化学习是一种“无中生有”的智能创造方式，其通过在AlphaGo项目中与深度学习“联姻”，引起了人们的广泛关注。AlphaGo的进阶版本AlphaZero更是通过纯粹的强化学习方法获得了优于AlphaGo的棋力。

上述研究均取得了很大成就，但都需要耗费巨大的计算资源和数据资源。然而，反观人类从蒙昧无知的婴儿逐渐长大成人的过程，你会觉得很有趣。知识和智慧的增长速度一开始很慢，但随着知识的增加，人类学习新知识的速度越来越快。这其中涉及到的一个关键问题是人类具有举一反三，或者说知识迁移的能力，这使得人类通过极少量的样本就可以完成有效的学习。比如，会骑自行车的人更容易学会骑摩托车；精通一门编程语言的人，学习其他编程语言也会觉得十分简单。

受到这一想法的启发，近年来迁移学习开始受到关注。而除了模仿和解释人类学习的机理之外，机器学习依赖大量数据的困扰也是迁移学习发展的动力。虽然在某些领域，我们已经积累了大量的数据，但仍有许多领域处于数据匮乏的状态，在这些

领域应用人工智能技术会异常困难。如果我们能使用迁移学习的方法论,就可以有效解决这些问题。例如,我们可以在和小数据领域 A 相邻的领域找到拥有大量数据的领域 B,如果 B 和 A 之间的知识迁移成功,那么在 A 领域就不用收集如此庞大的数据集了。基于其对人工智能领域的重要意义,迁移学习被认为是下一轮人工智能技术落地的关键。

迁移学习简述

迁移学习,顾名思义,就是把在某个领域获取的知识迁移到对另一个领域的学习中,也就是举一反三。人类对举一反三的理论性研究要追溯到 1901 年,心理学家桑代克 (Thorndike) 和伍德沃思 (Woodworth) 提出了学习迁移 (transfer of learning)^[1] 的概念。他们主要研究了人们学习某个概念时如何对学习其他概念产生迁移,这些理论对后来教育学的发展产生了重要影响。

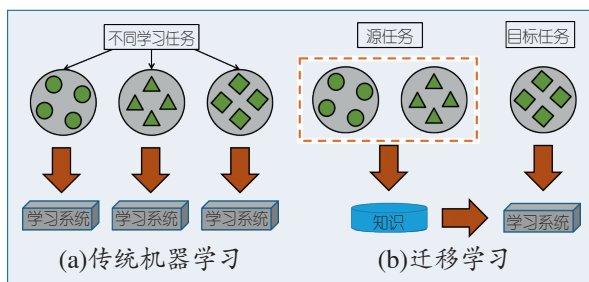


图1 传统机器学习与迁移学习

随着人工智能与机器学习的兴起,人们就想把学习迁移的思想应用到机器学习中。传统的机器学习,尤其是有监督学习,对数据的样本数量、数据分布的统一性、标签的完整性等都有着严苛的要求。而迁移学习解决的正是在机器学习任务中面对样本不足、标签不全等情况,如何借助外部其他分布的数据来有效地学习这一问题(见图1)。1990 年以来,大量研究都涉及迁移学习的概念,如自主学习、终生学习、多任务学习、知识迁移等^[2]。但是这些研究都没有形成一个完整的迁移学习体系。直到 2010 年,迁移学习的首个形式化定义被提出^[3],由此,

迁移学习成为机器学习中一个重要的分支领域。近些年,深度迁移学习、迁移强化学习的提出让我们看到了这一领域非凡的潜力。

按照迁移学习形式化的定义,它的目的是借助一个源数据集来学习目标数据集的一个预测函数。我们按照学习方法把迁移学习分成样本迁移、特征迁移、模型迁移和关系迁移四个类别。

样本迁移



图2 样本迁移示例

基于样本的迁移学习是试图通过对源数据中的每个样本赋予新的权重,使其更好地服务于新的学习任务。我们从源数据中挑选出和目标数据更相似的样本来参与训练,而剔除和目标数据不相似的样本^[4]。如图2所示,假如我们想训练一个模型来识别一幅图片中是否有狼,但是大部分包含狼的图片都没有标签,这使得传统的有监督学习难以生效。我们有另一个标签齐全的数据集,包含不同品种的狗的图片。我们的算法在观察少部分狼的图片以后,发现狗的图片中哈士奇和预测目标具有极其相似的特性,而贵宾犬显然不具备这种共性。因此,在借助狗的图片训练模型的时候,我们给包含哈士奇的样本赋予更大的权重,给包含贵宾犬的样本赋予更小的权重,甚至是零。如此便有效地利用了源数据,大大提高了在目标数据上预测的准确率。

样本迁移的主要宗旨是“各取所需”:剔除可能产生误导的样本;而对于特征相似、对任务有帮助的样本,则让其扩充训练数据,充分做到物尽其用。

特征迁移

特征迁移旨在通过引入源数据特征来帮助完成目标数据特征域的机器学习任务。一个机器学习任



图3 特征迁移示例

务中，可能由于目标特征域缺少足够的标签而导致学习的效果很差。通过挖掘源数据与目标数据的交叉特征结构，或者借助中间数据进行“桥接”，可以帮助我们目标数据特征上进行的机器学习任务实现不同特征空间之间的知识迁移。例如，我们在进行图片数据分类时缺少足够带有标记的训练数据，就可以借助已经标注好的文本数据，以及具有交叉特征的中间数据来协助提高在图片数据上的学习效果。如图3所示，在识别图片中花的种类的任务中，如果缺少花种类的标注数据，我们就可以通过自然带有标记的 wiki 等相关文本数据源获得带有标注的源数据以及同时具有文本和图片的中间数据，通过对特征空间的聚类来挖掘共同的特征结构，帮助提高这一学习任务的准确性。

特征迁移通常假设源域和目标域间有一些交叉特征，是从共同的特征空间的角度迁移知识，其主要研究方法包括特征的映射、迁移成分分析和基于神经网络的特征表示等。

模型迁移

模型迁移比样本迁移更加直接，也更加省时。模型迁移直接把源数据上训练完成的模型中有用的部分提取出来，直接应用到目标数据的训练模型上。这些模型参数可以作为目标模型的初始值，甚至是目标模型的一部分。如图4所示，我们已经训练好了一个决策树模型，通过判断一个人的各项体检指标来预测其是否患有糖尿病。我们想用另一棵决策树来判断一些人是否患有高血压。其中可能会共享许多模型参数，例如糖尿病人和高血压病人可能都

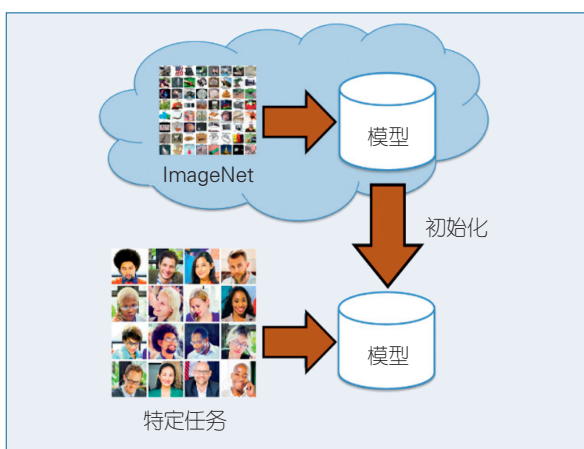


图4 模型迁移示例

有一个偏高的身体质量指数 (BMI)。通过共享这些相似的模型参数，我们有效地节约了目标模型的训练成本，加快了训练速度，提高了训练结果的质量。

模型迁移近年来在神经网络的加速收敛研究中起到了至关重要的作用，这主要得益于微调技术 (finetune)^[5] 被广泛认可，尤其是在图像识别领域。所谓微调，就是利用已经训练好的公开模型的参数作为初始值，在其基础上训练新的模型。例如，我们想要训练一个可以识别不同种类狗的图片分类器，可以利用网络上公开的 ImageNet^[6] 网络参数作为模型参数的初始值。这种方法可以避免模型的“从零训练”，从而大大加快神经网络的收敛速度。

关系迁移

关系迁移关注的是源域和目标数据域之间关系的相似性，通过从源领域挖掘与目标数据相关的关系模式，帮助在目标数据上进行机器学习任务。例

如生物病毒和计算机病毒之间，他们的相似关系包括了可复制性、传播性和破坏性；师生关系和上下级关系也具有相似性，包括服从性、学习性和指导性等，如图5所示。这些共同的关系模式可以帮助我们对于目标数据的分布和性质有更加深刻的了解。目前针对关系迁移的研究还相对较少，现有工作多通过逻辑网络来进行关系建模，从而描绘数据之间的关系模式。



图5 关系迁移示例

关系迁移不再局限于数据样本、特征和模型这些具体的数据表述方式，而是更深刻地挖掘数据内部和数据之间的外在联系和相关性，为更好地进行数据学习提供了新的角度。

迁移学习的前沿进展

传递迁移学习

传统的迁移学习对源数据和目标数据所在的领域有较强的限制条件，要求样本、特征或者数据间蕴含的关系有较强的相似性。该约束条件是迁移学习的思想基础，但同时也限制了迁移学习的进一步发展和更广泛的应用。因此，研究源数据和目标数据在弱相似性或者是看起来完全“不相似”情境下的传递迁移学习 (transitive transfer learning)^[7] 成为拓宽迁移学习应用范围的关键。

在传递迁移学习框架中，我们需要通过一个或

多个中间数据所拥有的知识，将两个不相关或是弱相关的源数据和目标数据联系在一起，形成一种知识的链式迁移。其针对的源数据和目标数据包括文本和图像数据，还包括属于同一类型但是语义完全不同的数据，通过联合矩阵分解或是深度神经网络等方法实现相互连接的具有弱相似性的知识迁移。目前已经有研究^[8]通过传递迁移学习实现了飞机图片和人脸图片这种弱相关的数据之间的知识迁移。传递迁移学习不仅冲击了传统迁移学习的约束，也为数据难获取，或数据量有限的小样本数据学习创造了新的技术视角和新的可能。

深度迁移学习

另一个与迁移学习相关的前沿研究是将深度学习与迁移学习结合起来。通过对深度学习模型的研究，人们发现对于相似的学习任务，虽然模型的最终目标可能不同，但模型前几层却常常具有相似的功能。这种相似的功能显示了深度学习模型前几层具有的可在多种目标数据间迁移的通用性。利用深度学习这一特点设计的迁移学习技术，一般被称为深度迁移学习。

图像识别是深度迁移学习的典型应用。针对不同图像识别任务（如车辆识别、人脸识别等）训练的深度学习模型，其前几层均有提取图像纹理的功能，而对图像纹理的有效提取则是各类图像识别任务的共同基础^[9]。因此，当需要进行某类图像识别任务而缺乏足够的支撑深度学习技术的大量标注数据时，可将用于识别其他类型图像的深度学习模型迁移过来。例如，2017年发表在《自然》杂志的一项成果^[10]，就利用了基于128万余张涉及千余类物品的图像训练的深度学习模型，通过深度迁移学习技术，仅用12万余张标注的皮肤癌图片，就训练出了优于人类专家的皮肤癌识别模型。此外，深度迁移学习在时空预测等领域也有应用。例如，预测城市交通状况是智慧城市管理的重要基础之一，然而一些欠发达城市缺乏足够的支撑深度学习技术的应用。这种情况就可以使用深度迁移学习，将在其他发达的、数据丰富的城市学习到的深度模型，

迁移到欠发达的、数据缺乏的城市中去^[11]。

迁移强化学习

自 AlphaGo 风靡全球以来, 强化学习就成为了人工智能领域炙手可热的研究方向。然而, AlphaGo 虽然功能强大, 但是其仅适用于围棋这一专门领域, 甚至我们只需把围棋的棋盘从 19×19 改成 21×21 , 就能使它的现有算法失效。因此, 研究者们开始思考, 如何利用已经学到的知识, 来帮助它学习更多的其他相似任务? 这就是迁移强化学习 (transfer reinforcement learning)^[12]。迁移强化学习指的是把迁移学习的技术应用到强化学习的智能体训练过程中。强化学习本质上是一种学习从环境到决策的映射从而使效益最大化的方法。目前, 强化学习的研究面临着多重挑战, 如难以从环境中获取足够反馈, 以及面对复杂任务或多项任务时的糟糕表现。而迁移强化学习从源任务选择、知识迁移、任务映射等多个角度对解决这些问题产生了至关重要的影响。

迁移强化学习的应用十分广泛, 例如任务导向型的对话系统^[13]。任务导向型的对话系统正在成为智能语音交互领域的一大热门, 京东智能客服、谷歌语音助手都属于这一范畴。它可以被看作是一个以用户满意度最大化为目标的智能代理, 因此用强化学习的方法来训练模型是合适之举。然而, 每个人的对话习惯各不相同, 这使得大样本数据的分布很不一致。搭建个性化的对话系统是一个很好的解决办法, 却又面临数据量不够的问题。迁移学习的介入有效地解决了两者之间的矛盾。它把其他所有人的对话样本看作源数据, 把当前用户的对话样本看作目标数据, 先从广泛的大众群体对话中学习出一种通用的策略, 再利用当前用户的对话数据使得策略精益求精, 从而满足个性化需求。

终身迁移学习

终身学习 (lifelong learning) 是一个非常吸引人的新领域, 它研究一个智能系统如何处理不断到来的各类任务, 从而实现终身不间断的学习。而终身

迁移学习则指在终身学习不同任务的过程中自适应地使用各种迁移学习技术来提高终身学习的有效性。然而, 传统的迁移学习都是由人来确定使用哪种迁移学习算法。一个终身学习的智能系统可能会面临各种需要迁移学习的场景, 而不同算法也有各自擅长的领域, 无法一概而论。同时, 我们也不希望有太多的人为干预, 不必每当遇到新的场景, 就由专家来指导智能系统该选用哪种算法。这就促成了自迁移学习 (learning to transfer)^[14] 的诞生。

自迁移学习是一种能由算法自主选择用什么来迁移以及如何去迁移的框架。它的核心思想是从过去已经实施过的一系列迁移学习任务中学习总结经验, 并把这些经验应用到未来可能出现的迁移学习任务中。自迁移学习旨在从过去的经验中学习两件事: 一是源数据和目标数据之间的差别对提升迁移学习效果的影响; 二是目标数据的判别力强弱如何反映迁移学习的效果。当我们遇到新的数据时, 只要计算出了上述两个衡量标准, 就能推算出使得提升效果最大化的迁移学习策略是什么。如此一来, 智能系统只需要预先学习少量知识, 便可以在无须专家的帮助下自主进行有效的终身迁移学习。

众包迁移学习

众包迁移学习 (crowd transfer learning) 是迁移学习与群体智能技术相融合的新产物。目前众包已经被广泛应用在人工智能领域以获取足够的标注数据, 但众包模式存在着高延迟和质量差距较大等诸多问题^[15]。在此基础上提出的众包迁移学习通过网络群体获取数据, 采用知识迁移来提升数据质量和数据规模, 降低数据获取成本。

众包迁移学习作为数据挖掘和人工智能领域一种全新的数据处理模式, 其在数据集成、数据清洗和数据标注方面都有较为典型的应用。在传统众包场景下其任务的参与者往往良莠不齐, 任务难度也不尽相同。如何判断任务的完成质量, 推测任务的真实结果是众包迁移学习的研究热点之一, 而交叉任务众包^[16]的提出是众包迁移学习的一个典型范例。该方法将历史任务的完成质量通过知识迁移的

方法迁移到正在进行的任务上,并利用概率图模型推断出新任务的完成质量。这种方法在数据清洗与降噪上取得了良好的效果,也使得众包数据集成的结果变得更加可靠。

对抗迁移学习

在互联网时代,用户经常对产品或服务表达满意程度。如果我们把对产品或服务的评论分成正向或负向,就需要一个系统来辨别每一个评论的取向,这个系统叫做舆情分析系统。传统的舆情分析首先需要有人来标注正、负向的关键词,然后由系统根据这些关键词建立舆情分类器。设想我们要为一个新领域建立舆情分析系统,但是其中的用户评论缺乏标注,也没有与之匹配的关键词库。在这种情况下,迁移学习可以帮助我们从相似领域的分类模型中迁移知识,建立新领域的模型。

在建立一个基于迁移学习的舆情分析模型时,我们可以利用领域的相似度来建立一个共有关键词库:一方面可以帮助在源领域进行分类,另一方面又与目标领域具有共性,也很难利用这些关键词来区分两个领域。这一迁移学习的思想可以用生成式对抗网络 GAN(Generative Adversarial Networks)来建立。在我们的工作^[17]中,挑选关键词时,首先考虑提高源领域的模型准确度,然后尽量降低这些词对两个领域的区分能力,通过互相对抗的过程做到端到端的学习。经实验验证,这些共有关键词可以很好地解释舆情的取向,为模型提供了良好的可解释性。

总结

机器学习未来的研究重点是小数据、个性化与可靠性。迁移学习能够有效利用耗费海量数据和算力获得的模型中的知识,具备小数据学习的能力。它正在打破人们脑中旧有的数据的概念,借助知识迁移的形式冲击数据之间的壁垒,为数据库、数据挖掘和人工智能等领域的下一步发展提供新的思路。人工智能不再只是数据与算力拥有者的“富人”游戏。■



杨强

CCF 专业会员、杰出演讲者。ACM、AAAI、IEEE、AAAS、IAPR Fellow, 香港科技大学冠名讲座教授, 国际人工智能联合会理事会主席、香港人工智能及机器人学会创会理事长、中国人工智能学会副理事长。主要研究方向为迁移学习、人工智能、大数据。qyang@cse.ust.hk



童咏昕

CCF 专业会员。北京航空航天大学卓越百人副教授。主要研究方向为众包计算、群体智能、数据库技术、人工智能与大数据系统。yxtong@buaa.edu.cn

参考文献

- [1] Woodworth R S, Thorndike E L. The influence of improvement in one mental function upon the efficiency of other functions(I)[J]. *Psychological review*, 1901.
- [2] Wirth K R, Perkins D. *Learning to learn*[M]. Springer Science & Business Media, 2012.
- [3] Pan S J, Yang Q. A survey on transfer learning[J]. *IEEE Transactions on Knowledge and Data Engineering*, 2010, 22(10): 1345-1359.
- [4] Dai W, Yang Q, Xue G, Yu Y. Boosting for transfer learning[C]// *ICML 2007*: 193-200.
- [5] Bengio Y, Lamblin P, Popovici D, et al. Greedy layer-wise training of deep networks[C]// *NIPS 2007*: 153-160.
- [6] Deng J, Dong W, Socher R, et al. Imagenet: A large-scale hierarchical image database[C]// *CVPR 2009*: 248-255.
- [7] Tan B, Song Y, Zhong E, et al. Transitive transfer learning[C]// *SIGKDD 2015*: 1155-1164.
- [8] Tan B, Zhang Y, Pan S J, et al. Distant domain transfer learning[C]// *AAAI 2017*: 2604-2610.
- [9] Long M, Cao Y, Wang J, et al. Learning transferable features with deep adaptation networks[C]// *ICML 2015*: 97-105.
- [10] Esteva A, Kuprel B, Novoa R A, et al. Dermatologist-level classification of skin cancer with deep neural networks[J]. *Nature*, 2017, 542(7639): 115.
- [11] Wang L, Geng X, Ma X, et al. Crowd flow prediction by deep spatio-temporal transfer learning[J]. *arXiv preprint arXiv:1802.00386*, 2018.
- [12] Taylor M E, Stone P. Transfer learning for reinforcement learning domains: A survey[J]. *Journal of Machine Learning Research*, 2009, 10(Jul): 1633-1685.

- [13]Mo K, Li S, Zhang Y, et al. Personalizing a dialogue system with transfer reinforcement learning[J]. arXiv preprint arXiv:1610.02891, 2016.
- [14]Wei Y, Zhang Y, Yang Q. Learning to transfer[J]. arXiv preprint arXiv:1708.05629, 2017.
- [15]Tong Y, Chen L, Zhou Z, Jagadish H V, Shou L, Lv W. SLADE: a smart large-scale task decomposer in crowdsourcing[J]. IEEE Transactions on Knowledge and Data Engineering, 2018, 30(8): 1588-1601.
- [16]Mo K, Zhong E, Yang Q. Cross-task crowdsourcing[C]// SIGKDD 2013: 677-685.
- [17]Li Z, Zhang Y, Wei Y, Wu Y, Yang Q. End-to-end adversarial memory network for cross-domain sentiment classification[C]//IJCAI 2017: 2237-2243.